

ИИ-интервьюер для технической оценки кандидатов

Статус документа: факты из материалов кейсодателя отделены от гипотез команды. Рыночные оценки из исследования требуют проверки перед Demo Day.

Проблема и чья это работа

После первичного отбора рекрутер Napoleon IT ищет внешнего технического эксперта, совмещает его календарь с календарём кандидата, организует часовое интервью и ждёт заключение. Внешние интервьюеры обходятся компании примерно в 300 000 ₽ в месяц; скорость найма зависит от их доступности.

Работа пользователя: когда кандидат прошёл первичный отбор, рекрутер и нанимающий менеджер хотят быстро получить сравнимую и доказательную техническую оценку, чтобы решить, двигать ли кандидата дальше, не организуя отдельное часовое интервью с внешним экспертом.

Как это работает сейчас

Первичный отбор → поиск эксперта → согласование слота → интервью ≈ 60 минут → письменный фидбек → решение рекрутера

Цена текущего процесса — оплата экспертов, время рекрутера и задержка найма. Точный объём интервью, ставка эксперта, время ожидания и доля сорванных интервью пока неизвестны.

Наше решение

Веб-сервис для асинхронного технического интервью:

вакансия + резюме → рубрика и вопросы → персональная ссылка → видеоответы → транскрибация → оценка по требованиям → доказательная карточка кандидата

Система сохраняет единое ядро вопросов для кандидатов одной вакансии, добавляет вопросы по резюме и задаёт ограниченное уточнение, если ответ слишком общий, противоречивый или не раскрывает личный вклад. ИИ оценивает каждый ответ по рубрике, приводит цитаты и таймкоды, разделяет подтверждённые и непроверенные навыки и выдаёт рекомендацию: «подходит», «не подходит» или «требуется дополнительная проверка». Финальное кадровое решение принимает человек.

Обязательные требования и предположения команды

Подтверждено материалами кейса	Требует проверки
Работающий сквозной веб-сценарий	5–7 вопросов и интервью длительностью 20–30 минут дадут достаточно сигнала
Вакансия, резюме, генерация и редактирование вопросов	Основной сегмент MVP — кандидаты уровня middle/middle+
Общее ядро вопросов и персонализация по резюме	Рубрика под вакансию повысит согласие ИИ с экспертом до целевых 80%
Не более 1–2 адаптивных уточнений к ответу — рекомендуемая рамка	Класс «дополнительная проверка» можно использовать как безопасное воздержание
Запись видео и аудио отдельно по каждому вопросу	Кандидаты примут асинхронный формат без заметного роста отказов
Транскрипт, оценки по требованиям, цитаты и таймкоды	Внешние ASR- и LLM-сервисы допустимы для прототипа
Согласие на запись, роли доступа, срок хранения и удаление данных	Технический словарь вакансии заметно улучшит распознавание терминов
Антифрод и live-coding — опциональны; ATS, почта и календарь не входят в MVP	Нанимающий менеджер сможет принять решение по карточке за несколько минут

Данные и доступы

Есть: вакансии Middle+ Python Developer; шесть примеров вопросов; обезличенные резюме; два примера транскриптов и итоговых заключений с баллами 6,67 и 8.

Не хватает: формального соответствия балла трём итоговым классам; оценок по отдельным требованиям; единой экспертной рубрики; распределения классов; исторических видео и аудио; независимой оценки второго эксперта; правил финального тестирования; ограничений на внешние API и место хранения данных.

Предоставленные примеры подходят для проверки пайплайна, но не для доказательства точности: двух интервью недостаточно для расчёта устойчивой метрики.

Аналоги и позиционирование

Аналог	Что закрывает	Пространство для отличия
VCV, Skillaz, Поток, Хантфлоу	ATS, запись видео, массовый скрининг	Доказательная оценка технического содержания по требованиям вакансии
Xenia AI, «Собесо»	ИИ-интервью и автоматические баллы	Прозрачная рубрика, цитаты, воспроизводимость и опубликованная методика проверки
«КадроБратия»	ИТ-фокус, тесты и код-ревью	Оценка открытых технических ответов без обязательного просмотра тимлидом
micro1 Zara	Близкий сценарий AI-техинтервью	Русский язык, данные в РФ, middle-кандидаты и настройка под вакансию компании

Предполагаемое отличие: не «ИИ вместо интервьюера», а проверяемая оценка по рубрике конкретной вакансии — с цитатами, уверенностью и безопасным переводом спорных случаев человеку.

Бэклог гипотез

H1 — самое рискованное предположение: ИИ может приблизиться к экспертной оценке

Если оценивать каждый ответ по рубрике конкретной вакансии, агрегировать оценки по обязательным требованиям и отправлять неопределённые случаи на дополнительную проверку, **то** система совпадёт с экспертным итоговым классом не менее чем в 80% случаев.

- Метрики: ассигасу по трём классам; confusion matrix; доля ложных «подходит»; доля «дополнительная проверка»; согласие по отдельным требованиям.
- Проверка: 20–30 исторических интервью, единая рубрика, слепая разметка минимум одним экспертом; настройка и финальная выборка разделены.
- Критерий первого успеха: $\geq 80\%$ совпадений, ложные «подходит» $\leq 10\%$, воздержание $\leq 25\%$. Пороги уточняются с кейсодателем.

Н2 — короткое интервью сохраняет полезный технический сигнал

Если сократить сценарий до 5–7 основных вопросов и 20–30 минут, **то** эксперт сможет вынести тот же итоговый класс, что и после текущего часового интервью.

- Метрика: совпадение классов короткой и полной версии; доля требований, по которым хватает данных.
- Проверка: эксперт оценивает полный транскрипт и сокращённую версию независимо.

Н3 — адаптивное уточнение раскрывает ответы без живого интервьюера

Если задавать одно уточнение при отсутствии примера, масштаба, результата или личного вклада, **то** доля ответов «недостаточно данных» снизится минимум на 20 п. п. без выхода интервью за 30 минут.

- Метрики: доля оценимых ответов до и после уточнения; длительность; релевантность уточнений по экспертной оценке.

Н4 — словарь вакансии снижает влияние ошибок распознавания

Если передавать ASR список технологий и терминов из вакансии и выполнять контекстную постобработку, **то** число ошибок в ключевых технических терминах снизится минимум на 30%, а итоговый класс будет реже меняться из-за транскрипции.

- Метрики: term error rate; WER; доля случаев, где класс на ASR-тексте отличается от класса на ручной расшифровке.
- Проверка: 30–50 фраз и ответов с Python-, Kafka-, PostgreSQL- и Kubernetes-терминами.

Н5 — доказательства сокращают время проверки результата

Если показать оценки по требованиям, цитаты, таймкоды, уверенность и непроверенные навыки, **то** нанимающий менеджер разберётся в результате за ≤ 5 минут и оценит обоснованность не ниже 4 из 5.

- Метрики: время до решения; оценка понятности; число переходов к полному видео; совпадение решения менеджера с экспертом.
- Проверка: 5–7 рекрутеров или нанимающих менеджеров выполняют сценарий по двум карточкам.

H6 — прозрачный сценарий снижает отказ кандидатов

Если до начала показать длительность, правила оценки, использование записи, имя/роль человека, который увидит результат, и дать тестовый вопрос, **то** не менее 80% начавших интервью завершат его.

- Метрики: start-to-completion; отказы по этапам; оценка справедливости и комфорта после интервью.
- Проверка: 10–20 представителей целевого грейда; отдельно фиксировать технические сбои и осознанный отказ.

H7 — человек нужен только для спорных случаев

Если система автоматически закрывает уверенные случаи, а человеку передаёт только ответы с низкой уверенностью и противоречиями, **то** потребность во внешних экспертных интервью снизится на 60–80% без роста ложных положительных решений.

- Метрики: доля автоматических и эскалированных случаев; экспертные часы; стоимость одного решения; false-positive rate.
- Проверка: ретроспективный расчёт на исторической выборке после проверки H1.

Открытые вопросы кейсодателю

1. Как устроена финальная тестовая выборка и что именно получает система на входе?
2. Кто, по какой рубрике и в каком формате создаёт эталонную оценку?
3. Как баллы 6,67 и 8 переводятся в три итоговых класса?
4. Какая ошибка критичнее и как учитывается класс «дополнительная проверка»?
5. Можно ли получить 20–30 исторических интервью и независимую разметку второго эксперта?
6. Какой грейд, стек и длительность интервью приоритетны для проверки?
7. Разрешены ли внешние ASR/LLM API и какие правила хранения и удаления данных действуют?

Команда и использование ИИ

- **Продукт, UX и валидация:** контекст, рубрика, эталонная разметка, пользовательский сценарий, исследования и защита.
- **AI и evals:** генерация вопросов, адаптивность, ASR, оценка по рубрике, агрегация, воспроизводимость и тесты.

- **Веб и инфраструктура:** запись, хранение, API, статусы обработки, карточка результата, доступ и деплой.

ИИ помогает анализировать материалы, готовить варианты вопросов и рубрик, писать прототип и прогонять evals. Команда не делегирует ИИ подтверждение пользовательской боли, выбор ключевой гипотезы, экспертную разметку и решение о готовности результата.

Ближайшая проверка

Сначала проверяем H1 на готовых транскриптах: вручную фиксируем рубрику и эталон, затем сравниваем с оценкой ИИ по каждому вопросу. Параллельно собираем сквозной сценарий на заглушках. Если оценка не работает, интерфейс не спасёт продукт; если работает — запись, адаптивность и UX усиливают доказанную ценность.

Источники

- «ТЗ от Анастасии Титовой» и «Рамка MVP — дополнение» — требования и критерии кейса.
- «Пример вакансии и вопросов» и «Пример детализации и анализа видео-интервью» — демонстрационные данные.
- «Context Pack: асинхронное AI-техинтервью» — рынок, доказательства и риски; оценки и пометки «из памяти» требуют верификации.
- «Установка 2-го дня: AI Product Hack» — структура Context Pack и формат гипотез.